新版本拟采用技术说明

1. 文档说明

项目	内容
文档名称	新版本拟采用技术说明
版本	v0.2
日期	2026-04-18
面向对象	甲方业务负责人、项目负责人、产品经理、实施团队
文档定位	用于向甲方说明新版本建设中拟采用的新技术方向、应用场景与业务价值
文档风格	甲方汇报稿，强调技术方向、业务目标、价值和边界，不展开底层实现细节

1.1 编写目的

在上一阶段系统建设中，平台已经完成了成果管理、项目过程管理、流程引擎、权限体系等核心基础能力。本次新版本的重点，不是推翻原有技术架构，而是在现有稳定架构上，引入更适合当前业务目标的新技术能力。

本文件用于向甲方回答以下问题：

- 新版本会继续沿用哪些成熟技术基础。
- 新版本重点引入哪些新技术。
- 这些新技术分别服务于哪些业务场景。
- 这些技术带来的价值是什么。
- 哪些能力属于辅助增强，而非全自动决策。

1.2 核心结论

新版本的技术升级思路可以概括为：

保留现有稳定业务底座，在其上增加“文档识别能力 + AI 理解能力 + 智能匹配能力 + 外部线索采集能力 + 规则协同能力 + 主题标准化能力”六类新技术支撑。

可进一步明确为：

- 科研成果管理系统中的 需求洞察、研究洞察、成果物自动补全 将在下一版本正式交付。
- 项目过程管理系统中的 合同识别 仍按既定节奏并行推进，作为另一系统的提效能力。
- 所有新技术统一定位为辅助识别、辅助判断和人工确认，不替代业务人员最终决策。

---

2. 当前技术基础保持不变

为了保证项目连续性、稳定性和交付可控性，新版本不会整体替换原有成熟技术底座，而是在以下基础上继续建设：

2.1 前端与后端基础架构

- 前端继续采用 Vue 3 + Element Plus。
- 后端继续采用 Spring Boot + MyBatis。
- 数据库仍以 MySQL 为主。
- 缓存能力继续基于 Redis。
- 相关动态字段配置为 Strapi。

2.2 项目过程管理底座

- 流程引擎继续采用 Camunda BPM。
- 身份认证与权限管理继续采用 Keycloak。

2.3 保持不变的原因

之所以保持这些基础架构不变，是因为它们已经承载了现有系统的主流程能力，具备以下优势：

- 架构成熟，风险可控。
- 已完成系统集成和现网适配。
- 有利于把新版本资源集中投入到真正需要增强的业务能力上。

因此，本次“新技术”强调的是能力增强，而不是技术底座重构。

---

3. 新技术迭代

3.1 项目文档上传与解析模块

3.1.1 核心功能设计

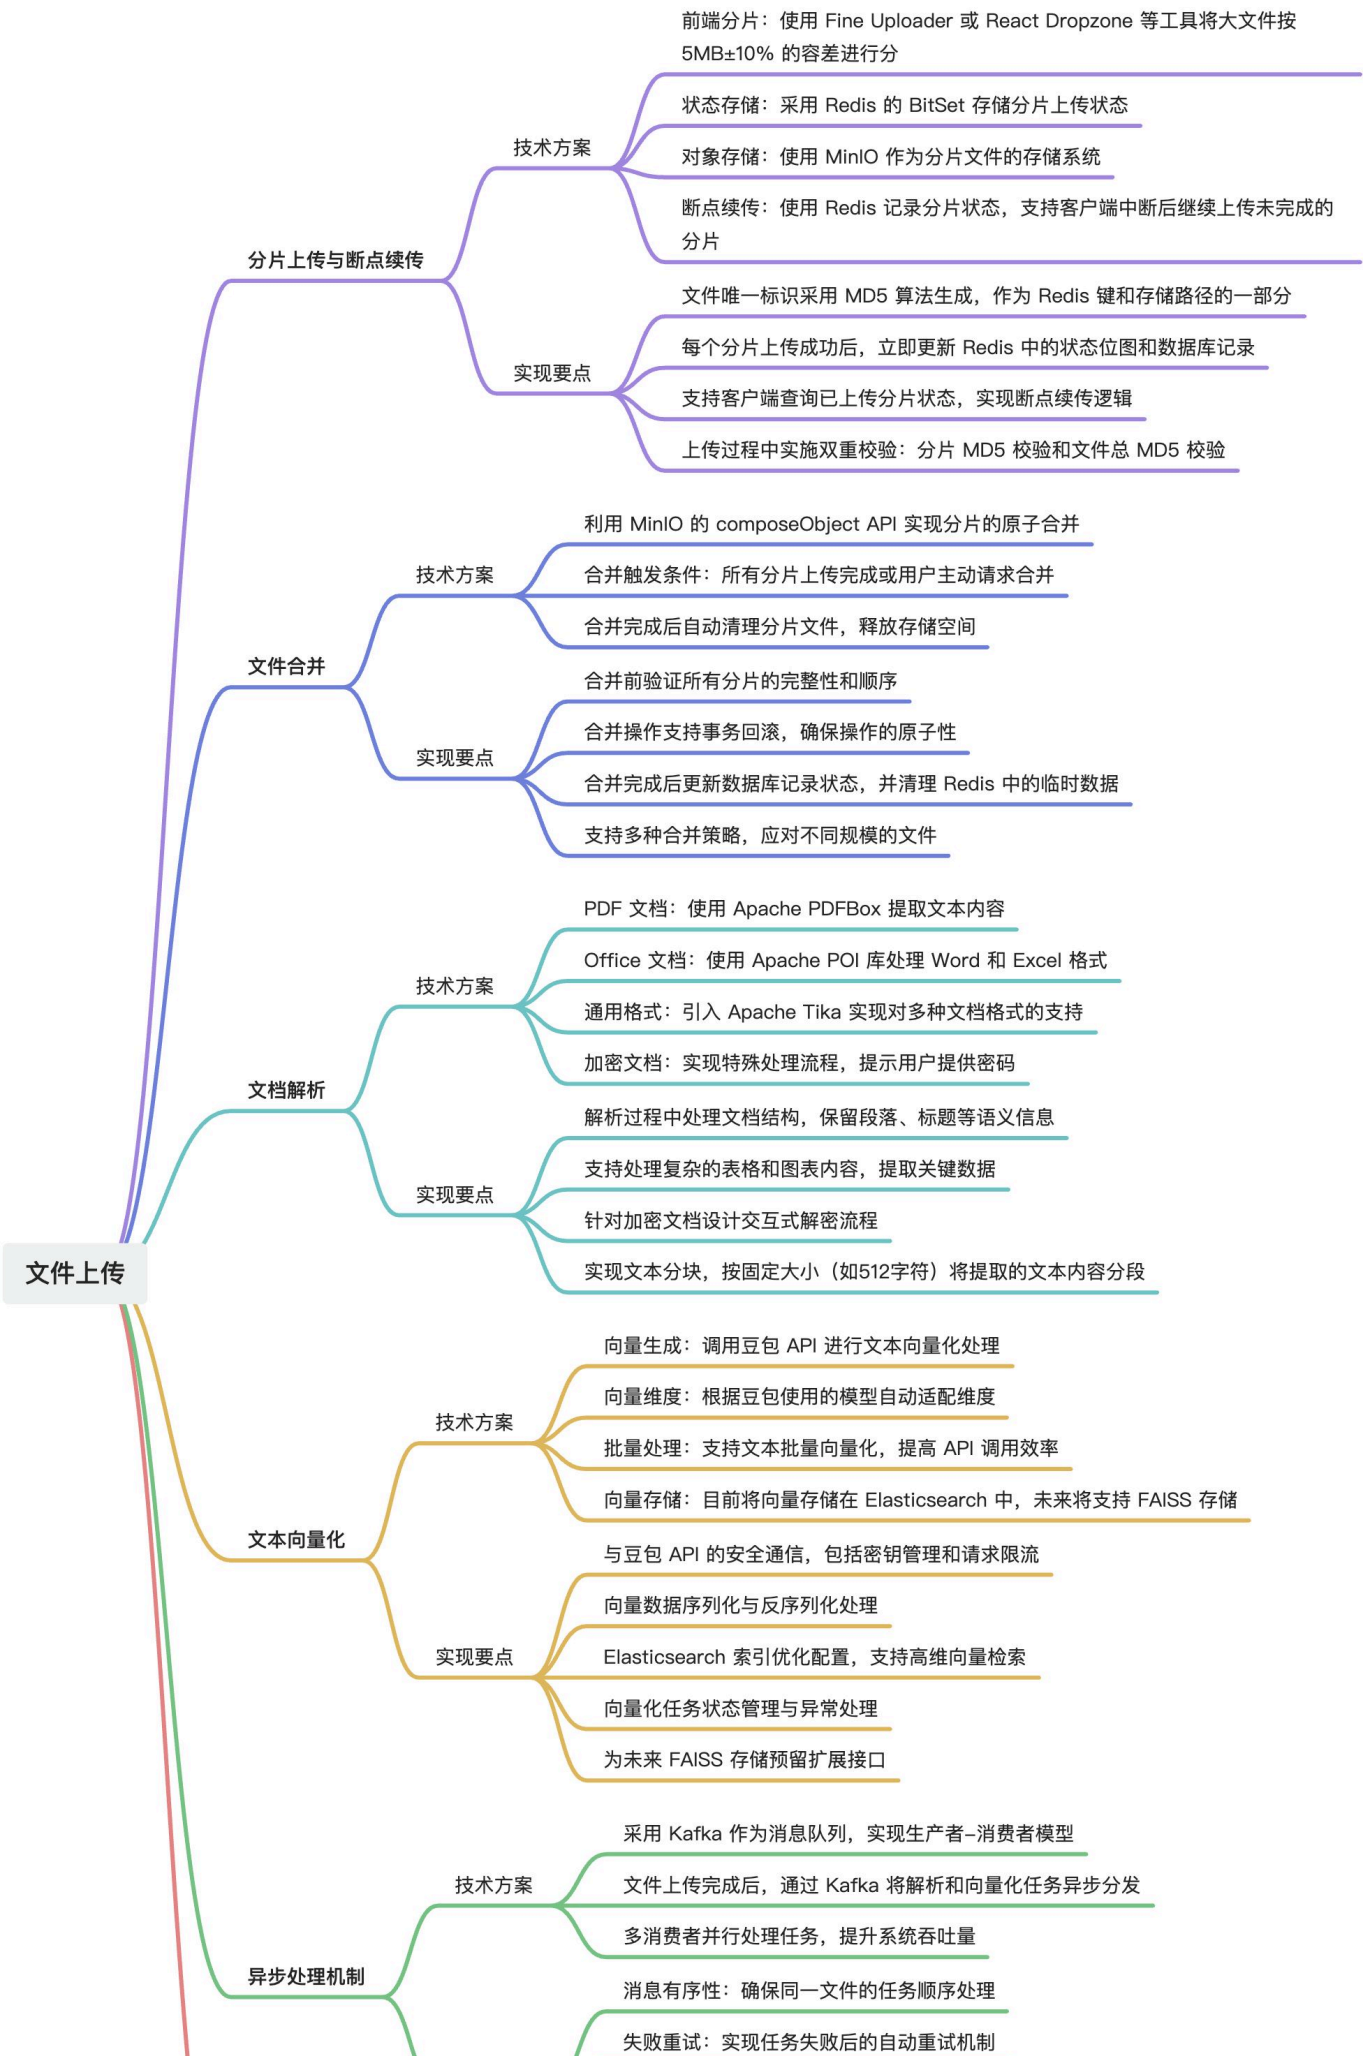
文件上传
分片上传与断点续传
技术方案
前端分片：使用 Fine Uploader 或 React Dropzone 等工具将大文件按 5MB±10% 的容差进行分
状态存储：采用 Redis 的 BitSet 存储分片上传状态
对象存储：使用 MinIO 作为分片文件的存储系统
断点续传：使用 Redis 记录分片状态，支持客户端中断后继续上传未完成的分片
实现要点
文件唯一标识采用 MD5 算法生成，作为 Redis 键和存储路径的一部分
每个分片上传成功后，立即更新 Redis 中的状态位图和数据库记录
支持客户端查询已上传分片状态，实现断点续传逻辑
上传过程中实施双重校验：分片 MD5 校验和文件总 MD5 校验
文件合并
技术方案
利用 MinIO 的 composeObject API 实现分片的原子合并
合并触发条件：所有分片上传完成或用户主动请求合并
合并完成后自动清理分片文件，释放存储空间
实现要点
合并前验证所有分片的完整性和顺序
合并操作支持事务回滚，确保操作的原子性
合并完成后更新数据库记录状态，并清理 Redis 中的临时数据
支持多种合并策略，应对不同规模的文件
文档解析
技术方案
PDF 文档：使用 Apache PDFBox 提取文本内容
Office 文档：使用 Apache POI 库处理 Word 和 Excel 格式
通用格式：引入 Apache Tika 实现对多种文档格式的支持
加密文档：实现特殊处理流程，提示用户提供密码
实现要点
解析过程中处理文档结构，保留段落、标题等语义信息
支持处理复杂的表格和图表内容，提取关键数据
针对加密文档设计交互式解密流程
实现文本分块，按固定大小（如512字符）将提取的文本内容分段
文本向量化
技术方案
向量生成：调用豆包 API 进行文本向量化处理
向量维度：根据豆包使用的模型自动适配维度
批量处理：支持文本批量向量化，提高 API 调用效率
向量存储：目前将向量存储在 Elasticsearch 中，未来将支持 FAISS 存储
实现要点
与豆包 API 的安全通信，包括密钥管理和请求限流
向量数据序列化与反序列化处理
Elasticsearch 索引优化配置，支持高维向量检索
向量化任务状态管理与异常处理
为未来 FAISS 存储预留扩展接口
异步处理机制
技术方案
采用 Kafka 作为消息队列，实现生产者-消费者模型
文件上传完成后，通过 Kafka 将解析和向量化任务异步分发
多消费者并行处理任务，提升系统吞吐量
消息有序性：确保同一文件的任务顺序处理
失败重试：实现任务失败后的自动重试机制

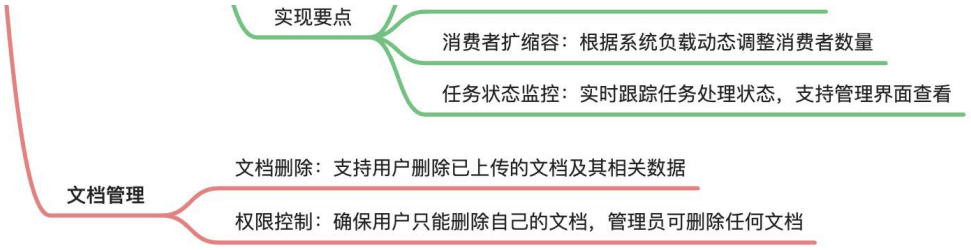

3.1.2 数据流转与存储设计

文件从上传到向量化完成的完整流程：

- 客户端计算文件 MD5，发起上传请求→服务端验证文件是否已存在，返回分片策略
- 客户端根据策略分片上传文件
- 服务端接收分片，存入 MinIO 并更新 Redis 状态
- 所有分片上传完成后，触发合并操作
- 合并完成后发送解析任务到 Kafka→解析服务消费任务，根据文件类型选择相应解析器提取文本
- 文本分块后发送向量化任务到 Kafka→向量化服务消费任务，调用豆包API 将文本转换为向量表示
- 向量数据写入 Elasticsearch 和预留 FAISS 接口→更新任务状态，通知用户处理完成

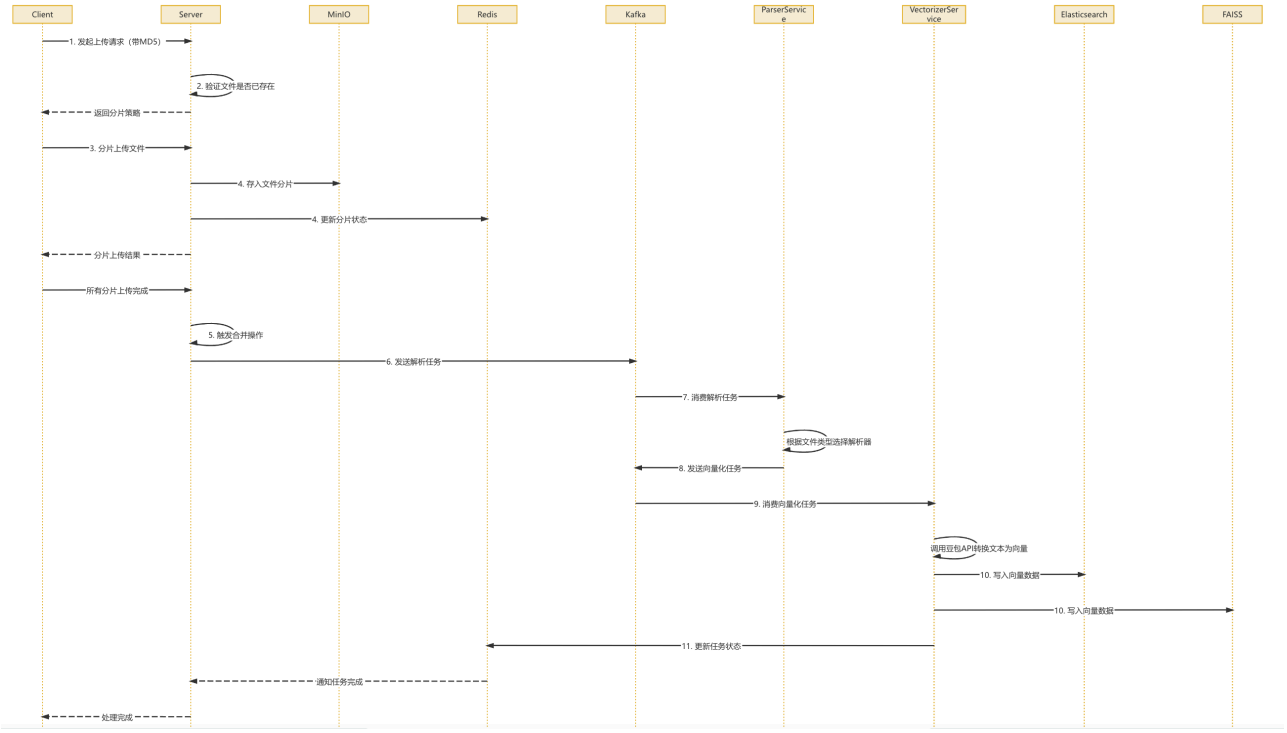

3.1.3 相关技术采用 MySQL

- 文件主表(file_upload)：存储文件元信息，如 MD5、名称、大小、状态
- 分片表(chunk_info)：记录每个分片的信息，包括索引、MD5、存储路径
- 解析结果表(document_vectors)：存储文本分块和向量化结果的元数据

Redis

- 使用 BitSet 记录已上传分片的位图（SETBIT命令）； 存储上传任务的临时状态和进度； 缓存热点文件的元数据，减轻数据库压力

MiniIO

- 临时分片：存储上传的文件分片，路径结构为/temp/{fileMd5}/{chunkIndex}

- 完整文件：合并后的文件存储在/documents/{userId}/{fileName}
- 存储策略：实现热冷数据分离

ES

- 存储文本向量数据和原始文本内容，索引基于文件 MD5 和分块 ID 组织

3.2 知识库检索设计方案 知识库检索模块是派聪明这个 RAG 项目的核心功能模块，我们是基于 Elasticsearch 实现的文档混合检索能力，将语义检索和关键词检索结果结合起来，为用户提供更高质量的搜索体验。 该模块依赖于文件上传与解析模块完成的向量化处理，直接使用存储在 Elasticsearch 中的向量数据进行检索。系统目前使用豆包 API 生成文本向量，并将向量存储在 Elasticsearch 中。

3.2.1 模块两大类 ①、知识库检索

- 混合检索：结合语义检索和关键词检索结果，按权重排序返回搜索结果
- 支持指定返回结果数量：通过 topK 参数控制结果数量

②、权限控制

- 此部分要连接keyclock
- 基于组织标签的数据权限：确保用户只能访问有权限的文档
- 支持层级权限验证：父标签权限自动包含所有子标签文档的访问权限
- 默认标签全局可访问：DEFAULT 标签资源对所有用户开放

功能模块	技术选型	备注
全文检索	Elasticsearch	第一阶段，使用IK分词器
向量检索	Elasticsearch	第一阶段，使用dense_vector类型
向量检索	*FAISS*	*第二阶段，提供更高性能的向量检索*
缓存	Redis	缓存热点查询结果
数据库	MySQL	存储元数据
对象存储	MinIO	存储文档文件

4. 新技术与两个系统的对应关系

新技术	科研成果管理系统	项目过程管理系统	主要价值
文档解析与 OCR	成果物自动补全	合同识别	降低录入和核对成本

新技术	科研成果管理系统	项目过程管理系统	主要价值
大模型与自然语言理解	需求摘要、研究热点归纳、成果附件文本理解	合同摘要	提高文本理解和归纳能力
语义匹配与向量检索	需求与成果匹配、研究主题聚合	暂不作为主场景	提高匹配相关性
白名单数据采集与调度	需求洞察	不作为本次主场景	建立外部线索入口
规则 + AI 组合判断	补全、标签、匹配解释	合同字段抽取与展示	提高稳定性与可控性
主题词标准化与知识组织	需求洞察、研究洞察	暂不作为主场景	统一主题表达和趋势口径

---

5. 下一版本内的技术支撑重点

5.1 直接支撑下一版本正式交付的技术能力

下一版本内，以下技术能力需要直接支撑科研成果管理系统三项正式交付：

- 用文档解析与 OCR 支撑成果物自动补全的附件识别与预填。
- 用白名单数据采集与调度支撑需求洞察的外部线索采集。
- 用大模型与自然语言理解支撑需求摘要、标签生成和研究热点总结。
- 用语义匹配与向量检索支撑需求与成果的候选匹配。
- 用规则 + AI 组合判断支撑结果可解释和人工确认流程。
- 用主题词标准化支撑研究洞察中的热点归类与趋势口径统一。

5.2 后续持续增强的技术方向

在下一版本完成正式交付后，后续可持续增强以下深度能力：

- 扩大成果附件识别的格式和类型覆盖范围。
- 增加更多白名单数据源和更细粒度的数据治理能力。
- 增强主题聚类、标杆对比和趋势分析深度。
- 优化匹配排序、解释质量和人工反馈学习机制。

---

6. 对甲方可感知的技术价值

从甲方视角看，这些新技术并不只是“技术升级”，而是直接对应业务结果的提升。

6.1 对科研成果管理系统

- 让成果录入更轻量。
- 让外部需求发现更主动。
- 让成果转化匹配更有依据。
- 让管理层看到更清晰的方向视图。

6.2 对项目过程管理系统

- 让合同上传和审核更高效。
- 让关键条款识别更快。
- 让流程节点中的人工工作更聚焦于确认，而不是重复翻阅材料。

6.3 对整体项目

- 在不推翻原有系统的前提下增强系统能力。
- 让新版本既体现技术先进性，又保持交付稳定性。
- 更适合作为后续持续升级的平台型能力建设。

---

7. 技术采用原则

建议本次新技术引入坚持以下原则：

7.1 以业务价值为先

不是为了“上 AI”而上 AI，而是围绕成果转化、成果录入提效、合同提效和管理洞察这些明确目标引入技术。

7.2 以现有架构为底座

不推翻既有成熟架构，在现有前后端、流程引擎和权限体系上做增强。

7.3 以可控交付为原则

优先建设可验收、可解释、可人工确认的能力，不追求一步到位的全自动化。

7.4 以辅助判断为边界

所有新技术统一坚持辅助识别、辅助判断、人工确认，不把技术输出直接等同于业务结论。

---

8. 风险与边界提示

8.1 数据基础风险

如果成果标签、主题词、需求标签缺少统一口径，研究洞察和需求匹配的质量会受到影响。

8.2 数据源稳定性风险

如果外部公开来源更新规则变化较大，需求洞察的数据持续性会受到影响，因此下一版本建议坚持白名单策略。

8.3 预期管理风险

如果把新技术理解为“完全自动化决策”，将直接推高验收预期。因此，需要持续强调人工确认边界。

---

9. 最终建议

建议与甲方形成以下统一技术结论：

新版本不重做底座，而是在现有稳定架构上，通过文档解析、自然语言理解、语义匹配、白名单采集、规则 + AI 和主题标准化等技术，直接支撑科研成果管理系统在下一版本正式交付需求洞察、研究洞察、成果物自动补全三项能力，并并行支撑项目过程管理系统的合同识别能力。